




FACULTAD de
CIENCIAS ECONÓMICAS

VARIABLES ALEATORIAS

ALAN REYES-FIGUEROA
ELEMENTS OF MACHINE LEARNING

(AULA 03) 15.ENERO.2025

Variables aleatorias



Definición

Sea $(\Omega, \mathcal{F}, \mathbb{P})$ un espacio de probabilidad. Una **variable aleatoria** (v.a.) es una función medible $X : \Omega \rightarrow \mathbb{R}$.

Aquí medible significa que si $X : (\Omega, \mathcal{F}, \mathbb{P}) \rightarrow (\mathbb{R}, \mathcal{B}(\mathbb{R}), \mu)$, entonces la preimagen de cualquier elemento en $\mathcal{B}(\mathbb{R})$ es un elemento de \mathcal{F} . Esto es, X^{-1} lleva conjuntos medibles de \mathbb{R} (bajo la medida de Lebesgue μ), a conjuntos medibles en \mathcal{F} (bajo la probabilidad \mathbb{P}).

A los elementos de $\mathcal{B}(\mathbb{R})$ se les llama los *borelianos* de \mathbb{R} .

Ejemplo

Elegimos al azar una persona de un grupo. De cada persona tenemos un registro de su edad, altura, peso, ...

Mapeamos cada persona ω a $X(\omega) = (X_1(\omega), \dots, X_d(\omega))$, donde por ejemplo $X_1(\omega)$ representa su edad, $X_2(\omega)$ su altura, etc.

Si el grupo de personas corresponde a una base de datos, entonces X regresa los campos de interés de cada registro. Las variables X_1, \dots, X_d son variables aleatorias.

En este ejemplo llamaremos a X como una variable aleatoria (en realidad X es un vector aleatorio).

Observaciones:

- una variable aleatoria determina una relación determinística.
- una variable aleatoria induce una función de probabilidad.

Definimos $\mathbb{P}_X(\cdot)$ como

$$\mathbb{P}_X(A) = P(\{\omega \in \Omega : X(\omega) \in A\}).$$

Escribimos $\mathbb{P}_X(\cdot)$ como $\mathbb{P}(\cdot)$.

Por ejemplo, $\mathbb{P}(X = x)$ denota $\mathbb{P}_X(X = x) = \mathbb{P}(\{\omega : X(\omega) = x\})$.

$\mathbb{P}(X < a)$ denota $\mathbb{P}_X(X < a) = \mathbb{P}(\{\omega : X(\omega) < a\})$.

Variables aleatorias

Caso discreto:

Definición

Diremos que X es una variable aleatoria **discreta** si su contradominio $I = X(\Omega)$ es enumerable y $\mathbb{P}_X(i) = \mathbb{P}(X = i)$ existe para cada $i \in I$.
(Comunmente se identifica el contradominio I con los naturales).

Definición

Al conjunto de probabilidades $\{\mathbb{P}_X(i)\}_{i \in I}$ le llamamos la **distribución** de X .
(En general, a \mathbb{P}_X se le llama la **función de masa de probabilidad**).

Definición

Si $X \in \mathbb{R}$, llamamos a $F_X(x) = \mathbb{P}(X \leq x)$ la **función de distribución** (acumulativa) de X .

Variables aleatorias

Caso continuo:

Definición

Considere la función $F : \mathbb{R} \rightarrow \mathbb{R}$, dada por

$$F_X(t) = \mathbb{P}(X \leq t).$$

Diremos que X es una variable aleatoria **continua** si existe una función no-negativa $f_X : \mathbb{R} \rightarrow \mathbb{R}$, tal que

$$F_X(t) = \mathbb{P}(X \leq t) = \int_{-\infty}^t f_X(x) dx.$$

Definición

En ese caso, a la función f_X le llamamos la **densidad de probabilidad** de X .

Obs! La función de densidad f_X no tiene por qué ser continua.

Ya sea en el caso discreto o continuo,

Definición

Si $x \in \mathbb{R}$, llamamos a $F_X(x) = \mathbb{P}(X \leq x)$ la **función de distribución** (acumulativa) de X .

En general, definimos la función de distribución para un vector aleatorio $X = (X_1, \dots, X_d)$ como

$$F_X(x_1, \dots, x_d) = \mathbb{P}(X_1 \leq x_1, \dots, X_d \leq x_d), \quad \forall (x_1, \dots, x_d) \in \mathbb{R}^d.$$

En este caso, llamamos a F_X la **función de distribución conjunta** de X_1, \dots, X_d .

Propiedades

Propiedades de \mathbb{P}_X y f_X :

Propiedad	X discreta	X continua
no-negativa	$\mathbb{P}_X(A) \geq 0$	$f_X(x) \geq 0$
suma total	$\sum_x \mathbb{P}_X(x) = 1$	$\int_{\mathbb{R}} f_X(x) dx = 1$
relación entre f_X y F_X	$\mathbb{P}(X = x) = F_X(x) - F_X(x^-)$	$f_X(x) = \frac{d}{dx} F_X(x)$
relación entre f_X y F_X	$F_X(x) = \sum_{t \leq x} \mathbb{P}(X = t)$	$F_X(x) = \int_{-\infty}^x f_X(t) dt$

Propiedades

Propiedades de F_X :

Propiedad	X discreta	X continua
limitada	$0 \leq F_X(x) \leq 1$	$0 \leq F_X(x) \leq 1$
monotonía	F_X no-decreciente	F_X no-decreciente
límite inferior	$F_X(t) = 0, \forall t < \min_{x \in I(\Omega)}$	$\lim_{x \rightarrow -\infty} F_X(x) = 0$
límite superior	$F_X(t) = 1, \forall t \geq \max_{x \in I(\Omega)}$	$\lim_{x \rightarrow +\infty} F_X(x) = 1$

Además, F_X tiene la propiedad de semi-continuidad inferior: F_X es continua por la derecha, con límites por la izquierda.

Variables aleatorias discretas

- distribución Uniforme $U[a..b]$,
- distribución Bernoulli $Ber(p)$,
- distribución Binomial $Binom(n, p)$,
- distribución Geométrica $Geom(p)$,
- distribución Poisson $Poisson(\lambda)$,

- distribución Rademacher $Rad(p)$,
- distribución Binomial Negativa $NB(r, p)$,
- distribución Hipergeométrica $Hypergeometric(N, K, n)$.


Variables aleatorias discretas

1. Distribución Uniforme

$$X \sim U[a..b] \Leftrightarrow \mathbb{P}(X = k) = \frac{1}{b-a+1}, \text{ para } k = a, a+1, \dots, b.$$

Obs.

- Esta distribución depende de dos parámetros (de localización): a y b .
- El caso $a = b$, con $\mathbb{P}(X = a = b) = 1$ se llama una v.a. *degenerada*.




Variables aleatorias discretas

2. Distribución Bernoulli

$$X \sim \text{Ber}(p) \Leftrightarrow \mathbb{P}(X = 1) = p, \mathbb{P}(X = 0) = 1 - p, \text{ para } 0 \leq p \leq 1.$$

Obs.

- La distribución es simétrica si, y sólo si, $p = 1/2$.
- $\mathbb{E}(X) = p$, $\text{Var}(X) = p(1 - p)$.



Variables aleatorias discretas

La distribución Bernoulli tiene una hermana gemela: la distribución de Rademacher.

$$X \sim \text{Rad}(p) \Leftrightarrow \mathbb{P}(X = 1) = p, \mathbb{P}(X = -1) = 1 - p, \text{ para } 0 \leq p \leq 1.$$

Preguntas:

- ¿Cuál es la media y varianza de la distribución $\text{Rad}(p)$.
- Sean X, Y v.a., con $X \sim \text{Ber}(p)$ y $Y \sim \text{Rad}(p)$. Escribir X en términos de Y , y Y en términos de X .

La distribución de Bernoulli es importante para escribir situaciones donde se cuenta la ocurrencia de eventos. La variable $X \sim \text{Ber}(p)$ cuenta o indica la ocurrencia del evento de interés.

Variables aleatorias discretas

3. Distribución Binomial


$$X \sim \text{Binom}(n, p) \Leftrightarrow \mathbb{P}(X = k) = \binom{n}{k} p^k (1-p)^{n-k}, \text{ para } k = 0, 1, \dots, n.$$

Interpretación: Si $\{X_i\}_{i=1}^n$ son v.a. i.i.d. con $X_i \sim \text{Ber}(p)$, entonces

$$X = \sum_{i=1}^n X_i \sim \text{Binom}(n, p).$$

Obs.

- La distribución es simétrica si, y sólo si, $p = 1/2$.
- $\mathbb{E}(X) = np$, $\text{Var}(X) = np(1-p)$.



Variables aleatorias discretas


4. Distribución Geométrica

$$X \sim \text{Geom}(n, p) \Leftrightarrow \mathbb{P}(X = k) = p(1 - p)^{k-1}, \text{ para } k = 1, 2, 3, \dots$$

Interpretación: Si $\{X_i\}_{i=1}$ son v.a. *i.i.d.* con $X_i \sim \text{Ber}(p)$, entonces
 X = el momento del primer éxito en $\{X_i\} \sim \text{Geom}(p)$.

Obs.

- La probabilidad va decayendo en forma geométrica con k .
- $\mathbb{E}(X) = \frac{1}{p}$.



Variables aleatorias discretas

5. Distribución Poisson


$$X \sim \text{Poisson}(\lambda) \Leftrightarrow \mathbb{P}(X = k) = \frac{e^{-\lambda} \lambda^k}{k!}, \text{ para } k = 0, 1, 2, \dots$$

En este caso,

$\mathbb{P}(X = k)$ = probabilidad de que el evento de interés ocurra k veces.

Obs.

- Cuenta el número de llegadas de un proceso con tiempos exponenciales $\text{Exp}(\lambda)$.
- $\mathbb{E}(X) = \lambda$. Representa el número esperado de veces que ocurra el fenómeno durante un intervalo dado.



Variables aleatorias continuas

- distribución Uniforme $U[a..b]$,
- distribución Normal $\mathcal{N}(\mu, \sigma^2)$,
- distribución Lognormal $\mathcal{LN}(\mu, \sigma^2)$,

- distribución Exponencial $Exp(\lambda)$,
- distribución Erlang $Erlang(n, \lambda)$,
- distribución Gamma $\Gamma(\alpha, \beta)$,
- distribución Beta $Beta(\alpha, \beta)$,

- distribución Weibull,
- distribución Pareto,
- distribuciones de valores extremos.

Variables aleatorias continuas

1. Distribución Uniforme

$$X \sim U[a..b] \Leftrightarrow f_X(t) = \frac{1}{b-a} \mathbf{1}_{[a,b]}(t).$$

Obs. Aquí la función $\mathbf{1}_{[a,b]}$ es una *función indicadora* o *función característica*, que indica cuál es el soporte de la distribución.

Recordemos que para cualquier subconjunto $A \subseteq \mathbb{R}$

$$\mathbf{1}_A(t) = \begin{cases} 1, & t \in A; \\ 0, & t \notin A. \end{cases}$$

Preguntas: ¿Cuál es la función de distribución F_X ? ¿ $\mathbb{E}(X)$, $\text{Var}(X)$?

2. Distribución Exponencial Dado un parámetro $\lambda > 0$, la distribución exponencial tiene densidad

$$f_X(t) = \lambda e^{-\lambda t} \mathbf{1}_{[0, \infty)}(t), \quad F_X(t) = (1 - e^{-\lambda t}) \mathbf{1}_{[0, \infty)}(t).$$

Obs.

- $\mathbb{E}(X) = \frac{1}{\lambda}$ y $\text{Var}(X) = \frac{1}{\lambda^2}$.
- En ocasiones, se parametriza en términos de su valor esperado $\theta = \frac{1}{\lambda}$:

$$f_X(t) = \frac{1}{\theta} e^{-t/\theta} \mathbf{1}_{[0, \infty)}(t).$$

Variables aleatorias continuas


3. Distribución Normal Dados dos parámetros $\mu \in \mathbb{R}$, $\sigma > 0$, la distribución normal tiene densidad

$$f_X(t) = \frac{1}{(2\pi\sigma^2)^{1/2}} \exp\left(-\frac{(x-\mu)^2}{2\sigma^2}\right) \mathbf{1}_{\mathbb{R}}(t).$$

Obs.

- $\mathbb{E}(X) = \mu$ y $\text{Var}(X) = \sigma^2$.
- La distribución es simétrica alrededor de μ .
- X no tiene una función de distribución elemental

$$F_X(x) = \int_{-\infty}^x f_X(t) dt.$$



Propiedades

1. Si $X \sim \mathcal{N}(\mu, \sigma^2)$, se tiene que $Z = \frac{X-\mu}{\sigma} \sim \mathcal{N}(, 1)$.
2. Si $X_1 \sim \mathcal{N}(\mu_1, \sigma_1^2)$ y $X_2 \sim \mathcal{N}(\mu_2, \sigma_2^2)$, y X_1, X_2 son independientes, entonces

$$X_1 + X_2 \sim \mathcal{N}(\mu_1 + \mu_2, \sigma_1^2 + \sigma_2^2)$$

3. Si $X \sim \mathcal{N}(\mu, \sigma^2)$, se tiene que $-X \sim \mathcal{N}(-\mu, \sigma^2)$.
4. En general, si $X \sim \mathcal{N}(\mu, \sigma^2)$, y $a, b \in \mathbb{R}$, entonces $Y = aX + b$ es normal, con

$$Y \sim \mathcal{N}(a\mu + b, a^2\sigma^2).$$

Teoremas importantes

Teorema (Desigualdad de Markov)

Si X es una v.a. no-negativa, $a > 0$, entonces

$$\mathbb{P}(X \geq a) \leq \frac{\mathbb{E}(X)}{a}.$$

Teorema (Desigualdad de Tchebyshev)

Si X es una v.a. con $\mathbb{E}(X)$ y $\text{Var}(X)$ finitas, $a > 0$, entonces

$$\mathbb{P}(|X - \mathbb{E}(X)| \geq a) \leq \frac{\text{Var}(X)}{a^2}.$$

Teoremas importantes

Teorema (Ley débil de los números grandes)

Sean X_1, X_2, \dots, X_n variables aleatorias i.i.d., con $\mathbb{E}(X_i) < \infty$. Entonces, para todo $\epsilon > 0$


$$\lim_{n \rightarrow \infty} \mathbb{P}\left(\left|\frac{X_1 + X_2 + \dots + X_n}{n} - \mathbb{E}(X)\right| > \epsilon\right) = 0.$$

Interpretación:

Se repite el experimento n veces, con resultados X_i .

$\mathbb{E}(X) = \mathbb{P}(A)$, entonces $\frac{X_1 + X_2 + \dots + X_n}{n}$ es el porcentaje de veces que ocurrió A .

La ley débil dice que el porcentaje de veces que A ocurrió en n repeticiones se aproxima a $\mathbb{E}(X)$.



Teoremas importantes

Teorema (Teorema Central de Límite)

Sean X_1, X_2, \dots, X_n variables aleatorias i.i.d., con $\mathbb{E}(X_i) = \mu$, $\text{Var}(X_i) = \sigma^2$ finitas. Entonces

$$\lim_{n \rightarrow \infty} \mathbb{P}\left(\frac{S_n/n - \mu}{\sigma/\sqrt{n}} \leq x\right) = \int_{-\infty}^x \frac{1}{\sqrt{2\pi}} e^{-t^2/2} dt.$$

Consecuencias:

$$\frac{S_n}{n} \sim \mathcal{N}\left(\mu, \frac{\sigma^2}{n}\right),$$

o equivalentemente

$$X_1 + \dots + X_n = S_n \sim \mathcal{N}(n\mu, n\sigma^2).$$

